

Iniciação Científica & Tecnológica

Universidade Presbiteriana Mackenzie



AUTOMAÇÃO DE TRANSCRIÇÃO E ANÁLISE DE REUNIÕES UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Matheus Barbosa Meloni — aluno pesquisador

Prof. Victor Inácio de Oliveira — orientador

Escola de Engenharia | Engenharia da Computação | Campus Higienópolis

Programa de Iniciação Científica (PIBIC/PIVIC) 2025–2026

Apoio institucional: Universidade Presbiteriana Mackenzie / CNPq

Iniciação Científica & Tecnológica

INTRODUÇÃO

Problema

O registro documental de reuniões sustenta a rastreabilidade de decisões em contextos acadêmicos e organizacionais. Conduzido manualmente, é oneroso, seletivo e dependente da interpretação do anotador, o que compromete sua fidedignidade em relação ao que foi efetivamente enunciado.

Fundamentos disponíveis

- Reconhecimento de fala robusto sob ruído (RADFORD et al., 2022).
- Representação semântica distribuída em nível sentencial (REIMERS; GUREVYCH, 2019).
- Segmentação textual orientada por embeddings (ALEMI; GINSPARG, 2015).

Lacuna

Tais recursos têm sido investigados de forma isolada. Permanece em aberto o comportamento do encadeamento aplicado ao português brasileiro — tanto na distribuição do custo computacional quanto na preservação da correspondência entre o resumo produzido e o trecho de áudio que o originou.

Pergunta de pesquisa

De que modo a integração entre reconhecimento de fala, representação semântica distribuída e sumarização neural produz documentação estruturada e rastreável de reuniões em português, e como o custo computacional se distribui entre as etapas?

Objetivo geral

Investigar a viabilidade dessa integração, caracterizando o comportamento do pipeline no processamento de registros orais de reuniões em português.

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

METODOLOGIA

Arquitetura do pipeline — cinco estágios encadeados

1. Pré-processamento do sinal acústico — remoção de silêncio nas extremidades (top_db = 25), normalização de pico, subtração espectral em blocos de 60 s e reamostragem para 16 kHz mono.
2. Transcrição / ASR (faster-whisper) — decodificação por feixe (beam_size = 5), filtro de atividade de voz (VAD) e idioma fixado em pt; saída segmentada com marcação temporal.
3. Estruturação semântica (Sentence-BERT) — janelas deslizantes de 500 tokens com sobreposição de 50; cada janela vira um vetor normalizado em L2.
4. Agrupamento temático — similaridade de cosseno contra limiar de 0,78, com fusão incremental gulosa; cada bloco é remapeado ao eixo temporal da reunião.
5. Sumarização (T5-small local, ou API externa por configuração) — três instruções fixas: decisões, pendências e próximos passos, mais uma visão geral.

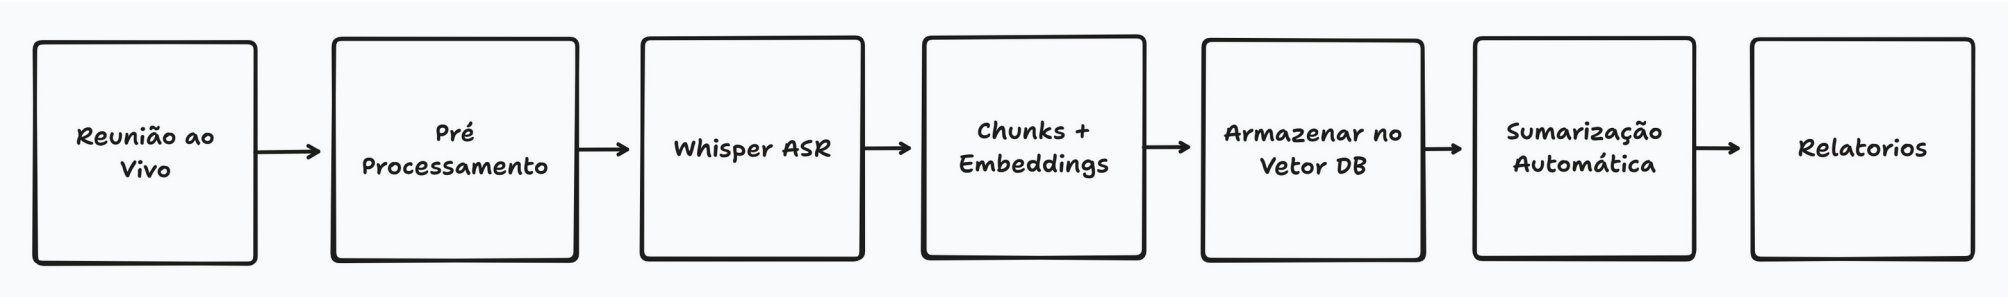


Figura 1 — Fluxo de ponta a ponta do pipeline.

Universidade Presbiteriana Mackenzie

Iniciação Científica & Tecnológica

METODOLOGIA

Arquitetura em camadas, reprodutibilidade e verificação

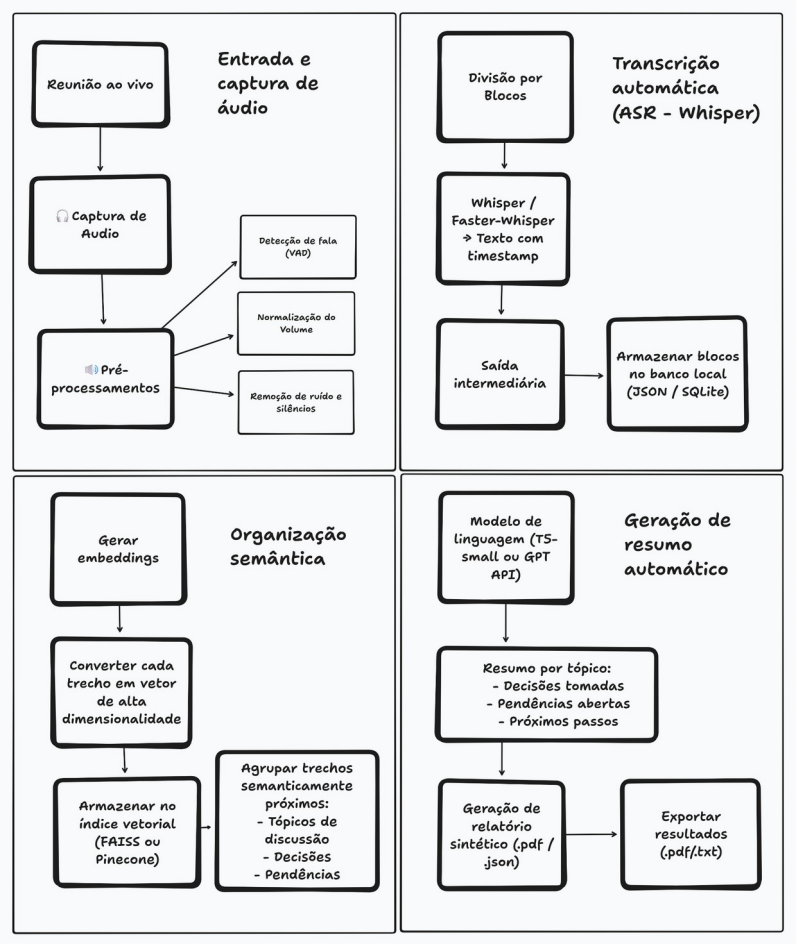


Figura 2 — As quatro camadas funcionais.

- Arquitetura em camadas — o núcleo de IA (src/) é independente das camadas de uso (linha de comando, API FastAPI, painel Streamlit, front-end Next.js) e pode ser testado sem subir interface.
- Configuração externalizada — modelo de ASR, embeddings, sumarizador, tamanho de janela, sobreposição e limiar de similaridade são variáveis de ambiente: uma rodada experimental é descrita por variáveis, não por alteração de código.
- Instrumentação — toda execução devolve stage_timings, com o tempo de cada etapa do pipeline e o tempo total de parede.
- Verificação — suíte automatizada em pytest com dublês de modelos: 15 testes em 6 módulos, cobrindo transcrição, embeddings, sumarização, upload, API e integração.
- Protocolo experimental — 2 a 4 cenários de áudio com perfis distintos; cada perfil estressa uma etapa diferente do pipeline.

Universidade Presbiteriana Mackenzie

RESULTADOS E DISCUSSÃO

Entrega funcional: o que o sistema efetivamente faz

- Pipeline integrado e operacional de ponta a ponta, acessível por três vias: linha de comando, API REST (GET /health, POST /transcribe) e painel Streamlit, além de front-end web.
- Saídas produzidas por execução:
  - transcrição com marcação temporal por segmento no formato [HH:MM:SS --> HH:MM:SS];
  - blocos semânticos rotulados, com intervalo de tempo aproximado na linha do tempo da reunião;
  - resumo em três seções — decisões, pendências e próximos passos — mais uma visão geral;
  - exportação em TXT, PDF e JSON, permitindo consumo humano e consumo por outro sistema.
- Robustez operacional: validação de upload (limite de 50 MiB e extensões .wav/.mp3/.m4a/.webm/.ogg), redução de ruído em blocos para gravações longas e empacotamento em Docker.
- Ferramentas de medição entregues: benchmark_pipeline.py agrega métricas de vários áudios em tabela; compare_whisper_models.py executa comparação A/B entre tamanhos de modelo.

Discussão: a modularidade foi validada na prática — o agrupamento foi reimplementado em NumPy puro, eliminando a dependência de FAISS, sem qualquer alteração nas camadas de interface.

RESULTADOS E DISCUSSÃO

Distribuição do custo computacional entre as etapas

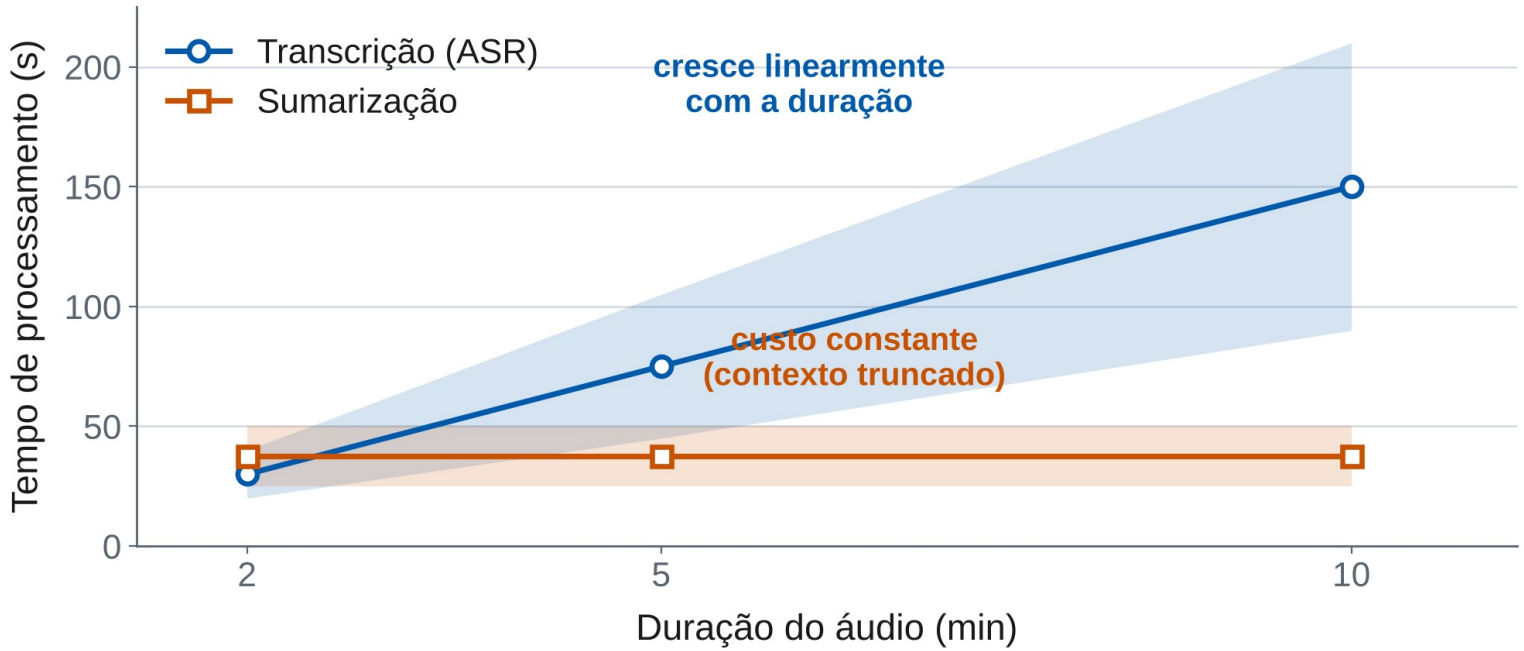


Figura 1 — Custo de processamento por etapa em função da duração do áudio; a faixa indica a amplitude projetada. Pré-processamento medido sobre o próprio pipeline (CPU x86-64, 4 núcleos, sem GPU).

- Achado: o custo concentra-se na transcrição e cresce linearmente com a duração, ao passo que a sumarização permanece constante — o truncamento do contexto em 300 tokens a torna independente do tamanho da reunião. Em consequência, o fator de tempo real melhora à medida que o registro se alonga.

RESULTADOS E DISCUSSÃO

Limitações, escopo e ameaças à validade

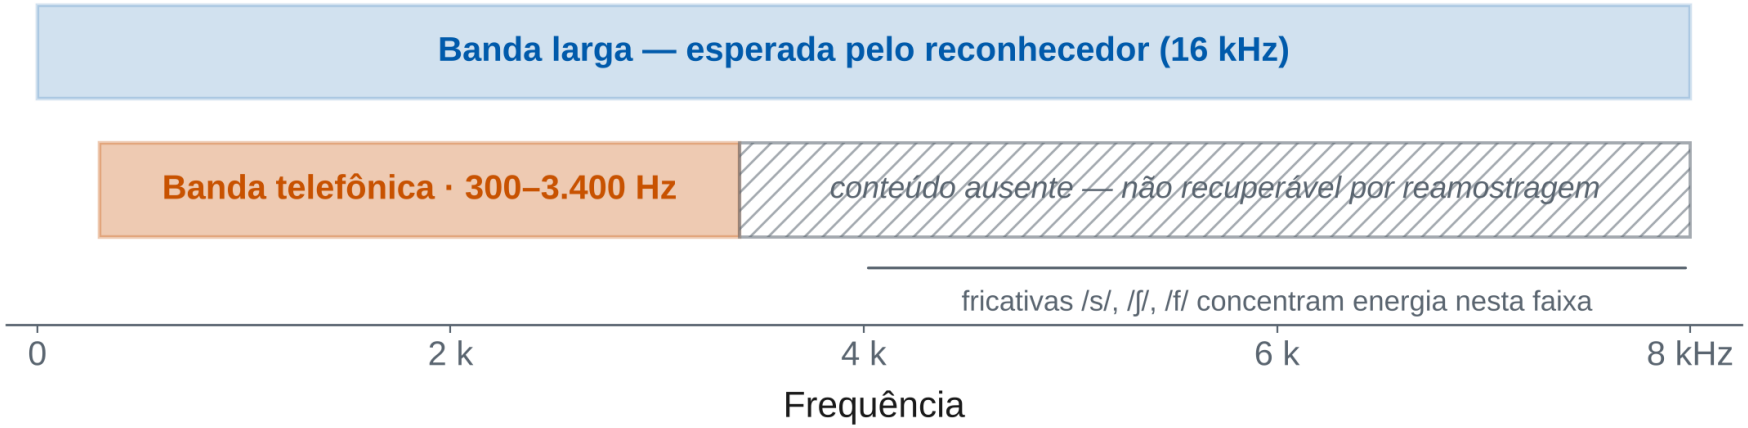


Figura 2 — Cobertura espectral da banda telefônica frente à banda esperada pelo reconhecedor.

- Escopo de captação — o delineamento pressupõe banda larga, a 16 kHz. Registros de telefonia, confinados a 300–3.400 Hz, não foram contemplados: a reamostragem não restitui o conteúdo espectral ausente, onde se concentra a energia das fricativas.
- Limite de segmentação — abaixo de cerca de três minutos o janelamento produz uma única janela e o agrupamento semântico não se efetiva; é restrição dos parâmetros adotados, não do modelo de representação.
- Ameaças à validade — conjunto reduzido de registros avaliados, avaliação qualitativa por avaliador único e tempos ainda não confirmados em rodada controlada.

Iniciação Científica & Tecnológica

CONSIDERAÇÕES FINAIS

Conclusão

Os resultados sustentam a viabilidade da integração investigada: há um pipeline reprodutível que converte registros orais em português em documentação estruturada e rastreável ao eixo temporal do áudio, com instrumentação em todas as etapas.

Contribuição

- Caracterização empírica da distribuição do custo computacional entre as etapas, até então não documentada para o encadeamento em português.
- Desenho experimental com configuração externalizada, que torna cada rodada descritível por parâmetros e, portanto, reprodutível por terceiros.

Limitação principal

A limitação não reside no reconhecimento de fala, mas na sumarização, cujo modelo foi treinado majoritariamente em língua inglesa — a transcrição mostrou-se consistentemente superior ao resumo dela derivado.

Desdobramentos

- sumarizador instruído em português (mT5/PTT5 ou modelo de linguagem com prompt estruturado);
- diarização de locutores, para atribuir decisões a seus responsáveis;
- agrupamento com otimização global, em substituição à estratégia gulosa por limiar;
- avaliação sob banda estreita e por métricas de erro de transcrição sobre corpus anotado.

Universidade Presbiteriana Mackenzie

REFERÊNCIAS

ALEMI, A. A.; GINSPARG, P. Text segmentation based on semantic word embeddings. arXiv:1503.05543, 2015.

MIKOLOV, T. et al. Efficient estimation of word representations in vector space. arXiv:1301.3781, 2013.

RADFORD, A. et al. Robust speech recognition via large-scale weak supervision. arXiv:2212.04356, 2022.

RAFFEL, C. et al. Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, v. 21, n. 140, p. 1-67, 2020.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using Siamese BERT-networks. In: EMNLP-IJCNLP, 2019. p. 3982-3992.

VASWANI, A. et al. Attention is all you need. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NeurIPS), 2017.

Conferir a formatação final conforme a NBR 6023 adotada pela unidade acadêmica.

AGRADECIMENTOS

À Universidade Presbiteriana Mackenzie e ao Programa de Iniciação Científica, pelo apoio institucional à pesquisa.

Ao Prof. Victor Inácio de Oliveira, pela orientação ao longo do projeto.