VIII SIMAC

SIMPÓSIO ACADÊMICO

TEMA

INOVAÇÃO, SUSTENTABILIDADE E EMPREENDEDORISMO

AUTOMAÇÃO DE TRANSCRIÇÃO E ANÁLISE DE REUNIÕES UTILIZANDO INTELIGÊNCIA ARTIFICIAL

Matheus Barbosa Meloni, matheus.b.meloni@gmail.com, Universidade Presbiteriana Mackenzie
Victor Inácio de Oliveira, victor.inacio@mackenzie.br, Universidade Presbiteriana Mackenzie

Introdução

Reuniões concentram decisões, pendências e encaminhamentos, mas o registro depende de anotação manual: é custoso, parcial e raramente rastreável ao que foi efetivamente dito.

O avanço do Reconhecimento Automático de Fala e do Processamento de Linguagem Natural tornou viável automatizar esse registro: o Whisper transcreve com robustez mesmo sob ruído (RADFORD et al., 2022) e a segmentação por embeddings supera métodos baseados em palavras-chave (ALEMI; GINSPARG, 2015).

As soluções comerciais equivalentes são proprietárias, orientadas ao inglês e dependentes de nuvem, o que impede auditar o processo e impõe restrições de privacidade sobre o áudio.

Objetivos

Objetivo geral

Desenvolver um sistema modular, reprodutível e executável localmente que converta áudio de reuniões em português em documentação acionável: decisões, pendências e próximos passos.

Objetivos específicos

- Integrar transcrição automática, estruturação semântica por embeddings e sumarização em um pipeline único e instrumentado.
- Isolar o núcleo de IA das camadas de uso — linha de comando, API e interface web —, tornando-o reutilizável e testável.
- Instrumentar o desempenho por etapa e avaliar o sistema sob protocolo reprodutível.

Metodologia

Pipeline modular de cinco estágios, cada um com responsabilidade única e saída definida para o seguinte.

1. Pré-processamento: remoção de silêncio, normalização de pico, subtração espectral em blocos de 60 s e reamostragem para 16 kHz mono.

2. Transcrição (faster-whisper): busca em feixe (beam_size = 5), filtro de atividade de voz e idioma fixado em português, com marcação temporal por segmento.

3. Estruturação semântica (Sentence-BERT): janelas de 500 tokens com sobreposição de 50, convertidas em vetores normalizados.

4. Agrupamento: similaridade de cosseno contra limiar de 0,78, com os blocos remapeados ao eixo temporal.

5. Sumarização (T5): três instruções fixas — decisões, pendências e próximos passos.

A configuração é externalizada em variáveis de ambiente: cada rodada experimental é descrita por parâmetros, não por alteração de código.

Resultados preliminares

O pipeline está operacional de ponta a ponta, acessível por linha de comando, API REST e interface web. Cada execução exporta a transcrição com marcação temporal e o resumo estruturado em PDF e JSON, permitindo rastrear cada item do resumo até o minuto do áudio.

A instrumentação por etapa mostrou que o custo é dominado pela transcrição e cresce linearmente com a duração, enquanto a sumarização permanece constante, por ter o contexto limitado a 300 tokens. Assim, o fator de tempo real (RTF) melhora conforme a reunião cresce: de 0,41–0,78 em 2 min para 0,21–0,45 em 10 min.

Pré-processamento medido sobre o próprio pipeline (CPU x86-64, 4 núcleos, sem GPU); demais etapas projetadas para a mesma classe de hardware.

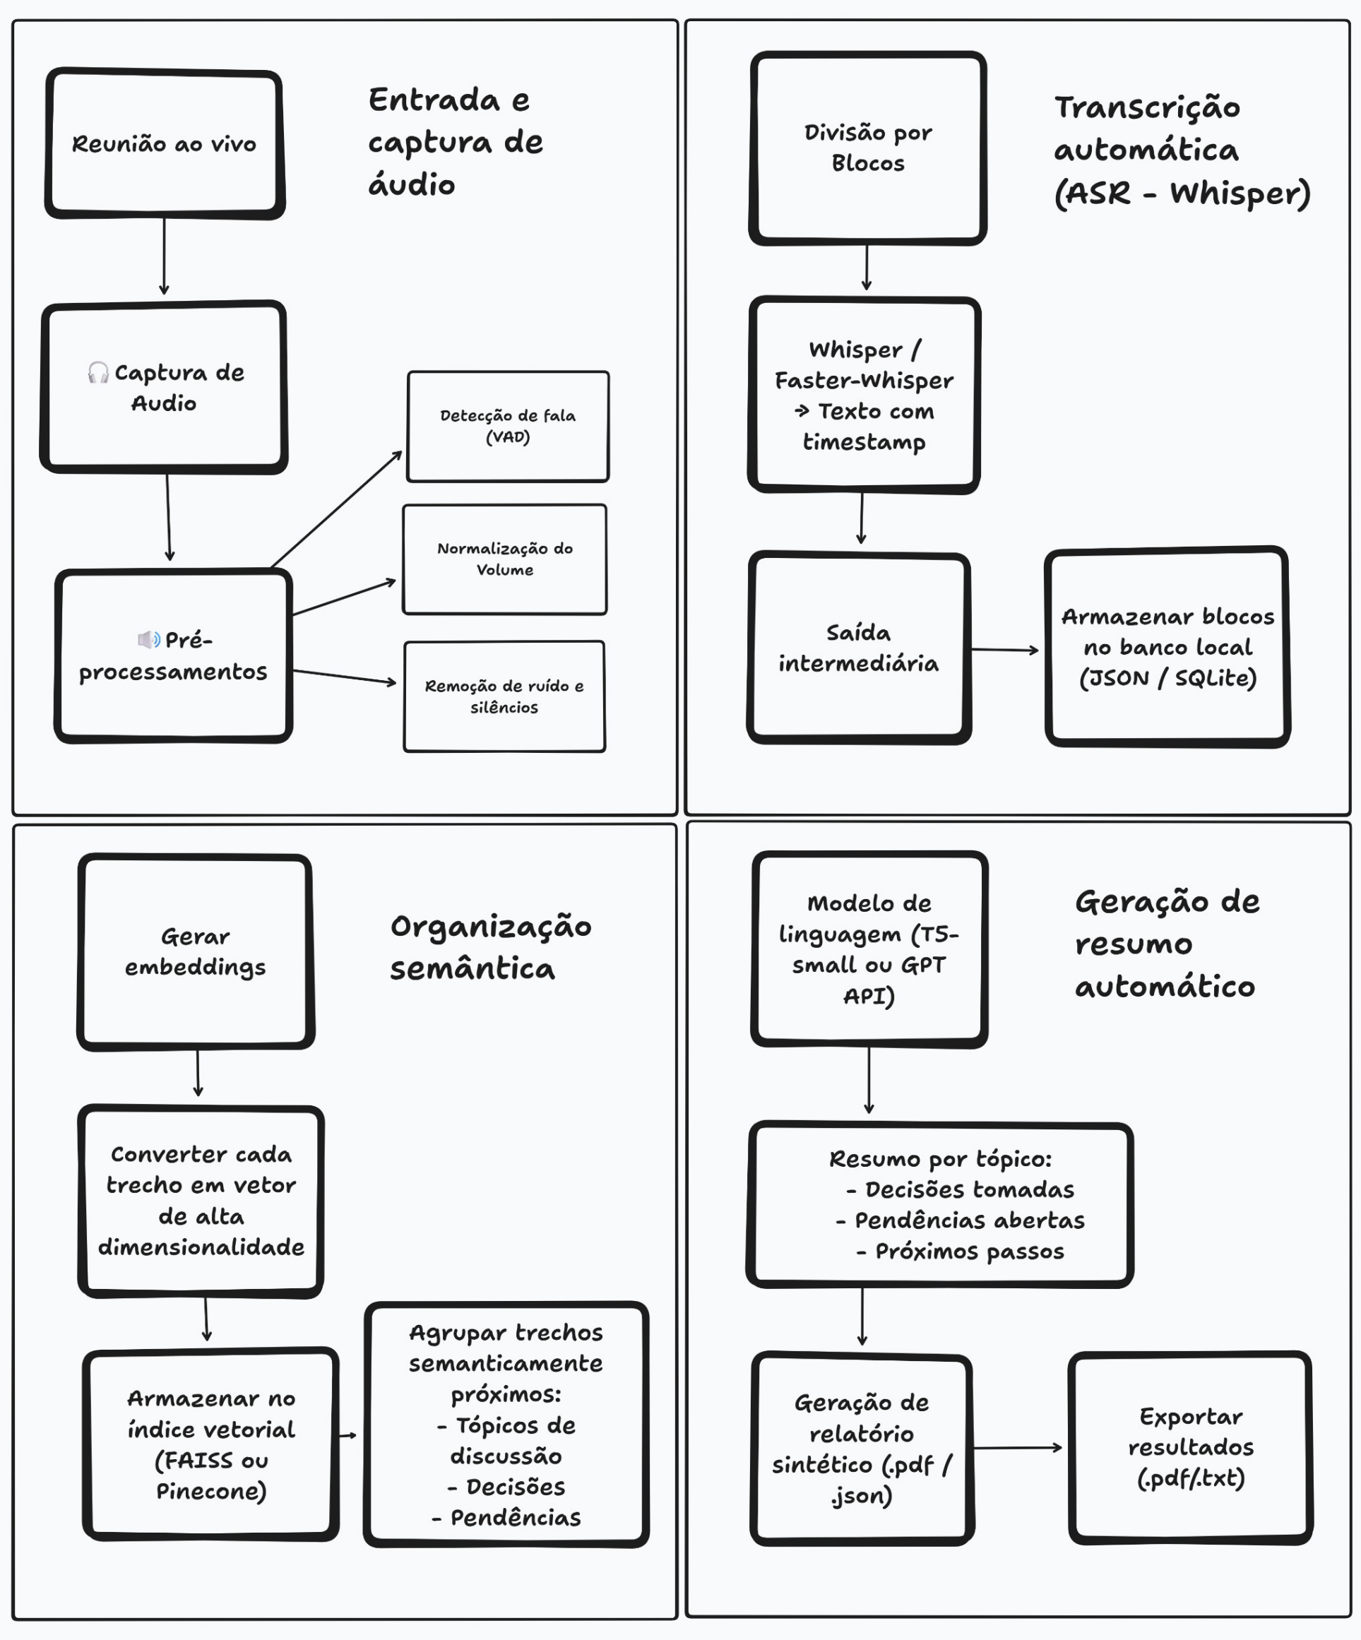

Entrada e captura de áudio
Reunião ao vivo
🎧 Captura de Audio
🔉 Pré-processamentos
Detecção de fala (VAD)
Normalização do Volume
Remoção de ruído e silêncios
Transcrição automática (ASR - Whisper)
Divisão por Blocos
Whisper / Faster-Whisper → Texto com timestamp
Saída intermediária
Armazenar blocos no banco local (JSON / SQLite)
Organização semântica
Gerar embeddings
Converter cada trecho em vetor de alta dimensionalidade
Armazenar no índice vetorial (FAISS ou Pinecone)
Agrupar trechos semanticamente próximos: - Tópicos de discussão - Decisões - Pendências
Geração de resumo automático
Modelo de linguagem (T5-small ou GPT API)
Resumo por tópico: - Decisões tomadas - Pendências abertas - Próximos passos
Geração de relatório sintético (.pdf / .json)
Exportar resultados (.pdf/.txt)

Figura 1 — Arquitetura em quatro camadas funcionais. Fonte: autoria própria (2026).

Considerações finais

O objetivo foi atingido no nível de sistema: há um pipeline reprodutível que converte áudio de reunião em documentação estruturada e rastreável ao tempo do áudio.

O gargalo de qualidade está na sumarização, que emprega um modelo pequeno treinado majoritariamente em inglês. Os próximos passos são um sumarizador instruído em português, diarização de falantes e avaliação com WER/CER sobre corpus anotado.

Referências

ALEMI, A. A.; GINSPARG, P. Text segmentation based on semantic word embeddings. arXiv:1503.05543, 2015.

RADFORD, A. et al. Robust speech recognition via large-scale weak supervision. arXiv:2212.04356, 2022.

RAFFEL, C. et al. Exploring the limits of transfer learning with a unified text-to-text transformer. Journal of Machine Learning Research, v. 21, n. 140, p. 1-67, 2020.

REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using Siamese BERT-networks. In: EMNLP-IJCNLP, 2019. p. 3982-3992.

FACULDADE ENGENHEIRO SALVADOR ARENA

CEBAS
CERTIFICAÇÃO DE ENTIDADES BENEFICENTES
DE ASSISTÊNCIA SOCIAL NA ÁREA DE EDUCAÇÃO